Языковой претрейн командного KDA-декодера перед переходом к ASR

ФИО: Тарасова Дарья Алексеевна

1 Задача

Требовалось выполнить языковой претрейн декодера до перехода к целевой ASR-задаче. Готового checkpoint для декодера нужного размера не было, поэтому обучение начиналось со случайной инициализации.

Эксперимент необходимо было спланировать с учётом одной GPU NVIDIA Tesla T4 и небольшого размера модели. В качестве контрольной точки перед переходом к ASR требовалось зафиксировать validation loss и perplexity на отложенной выборке.

1.1 Необходимость языкового претрейна

Декодер в ASR-модели должен не только использовать акустическую информацию, но и моделировать закономерности выходного текста. Text-only претрейн позволяет предварительно обучить языковую составляющую декодера, а затем использовать полученные веса как начальную точку для обучения полной ASR-модели.

На этапе языкового претрейна декодер обучался предсказывать следующий токен по предыдущему текстовому контексту. Для этого минимизировалась функция потерь

$$\mathcal{L}_{LM} = -\frac{1}{N}\sum_{t=1}^{N} \log p(y_t \mid y_{<t}),$$

где y_t — правильный следующий токен, а $y_{<t}$ — предыдущие токены последовательности. В реализации данная функция соответствовала causal cross-entropy со сдвигом предсказаний и правильных ответов на один токен.

Снижение validation loss с 8.8111 до 5.7482 показывает, что декодер научился лучше моделировать русскоязычные текстовые последовательности. Однако эти метрики характеризуют только языковую задачу и не доказывают улучшение качества распознавания речи.

Для проверки практической значимости претрейна необходимо сравнить две одинаковые ASR-модели: с предварительно обученным декодером и с декодером со случайной инициализацией. Основной метрикой такого сравнения должна быть WER на одном и том же отложенном аудионаборе.

2 Подходы и инструменты

Претрейн был сформулирован как задача causal language modeling: по предыдущим токенам декодер предсказывает следующий токен.

Использовались:

- PyTorch;

- Hugging Face Transformers и Trainer;
- пакет `flash-linear-attention`;
- командный класс `KDACrossAttentionDecoder`;
- финальный BPE-токенизатор команды;
- Kaggle с одной NVIDIA Tesla T4;
- смешанная точность FP16.

Для оценки использовались две метрики:

- validation loss;
- perplexity, вычисляемая как

$$\mathrm{PPL} = \exp(\mathcal{L}),$$

где $\mathcal{L}$ — validation loss.

В качестве функции потерь использовалась cross-entropy для задачи causal language modeling. На каждой позиции модель предсказывала следующий токен последовательности, после чего предсказание сравнивалось с правильным токеном. Padding-позиции не учитывались при вычислении loss.

3 Реализация

В эксперименте использовался класс `KDACrossAttentionDecoder` из командного репозитория. Архитектура декодера была разработана командой «Модели и архитектура».

Для языкового претрейна декодер запускался только на текстовых последовательностях. Поскольку аудиоданные на этом этапе не использовались, cross-attention был отключён, а его параметры не обновлялись.

В ходе претрейна обучалась языковая часть командного декодера, предсказывающая следующий текстовый токен.

Для обработки текстов использовался финальный BPE-токенизатор, подготовленный Маргаритой. Размер его словаря составлял 6390 токенов. В эксперимент вошли 1000 русскоязычных текстовых транскрипций Google FLEURS: 900 использовались для обучения, а 100 — для validation.

Основные параметры запуска:

Параметры претрейна

Параметр	Значение
Общее количество параметров	12 326 296
Количество обучаемых параметров	9 959 320
Количество шагов	200
Batch size на GPU	2
Gradient accumulation	8
Effective batch size	16
Learning rate	$3 \cdot 10^{-4}$
Точность	FP16
GPU	NVIDIA Tesla T4
Validation	каждые 25 шагов
Сохранение checkpoint	каждые 25 шагов

До начала обучения была выполнена оценка случайно инициализированной модели. После каждого 25-го шага повторно вычислялся validation loss. Лучший checkpoint выбирался по минимальному validation loss.

После завершения обучения были сохранены веса модели, конфигурация, токенизатор, параметры обучения и JSON-файл с итоговыми метриками.

3.1 Адаптация декодера к text-only режиму

Первоначальная версия командного декодера была рассчитана на использование внутри полной ASR-модели и требовала передачи выходов Whisper-энкодера. Кроме того, она не принимала `labels` и самостоятельно не вычисляла языковую функцию потерь.

Для поддержки отдельного языкового претрейна командой была добавлена возможность запуска без акустических представлений, вычисление causal language modeling loss и пропуск cross-attention в text-only режиме.

4 Результаты

Итоговые показатели претрейна:

Метрики до и после обучения

Метрика	До обучения	После обучения
Validation loss	8.8111	5.7482
Perplexity	6708.28	313.64

Validation loss последовательно снижался:

$$7.9910 \to 6.5908 \to 6.3884 \to 6.2007 \to 6.0312 \to 5.8507 \to 5.7702 \to 5.7482.$$

Дополнительные результаты:

- время обучения: 114.9 секунды, примерно 1 минута 55 секунд;
- лучший checkpoint: шаг 200;
- validation loss снизился на 3.0629;
- perplexity уменьшилась примерно в 21.4 раза.

Последовательное снижение validation loss показывает, что языковая часть декодера обучалась поставленной задаче и на рассмотренном числе шагов не демонстрировала ухудшения качества на отложенной выборке.

5 Итог

В результате был выполнен полный цикл языкового претрейна непосредственно класса `KDACrossAttentionDecoder`: случайная инициализация, обучение на одной T4, регулярная оценка на validation-выборке, выбор лучшего checkpoint и сохранение артефактов эксперимента.

Контрольными точками перед переходом к ASR являются:

- validation loss: 5.7482;
- perplexity: 313.64;
- checkpoint шага 200.

Полученный checkpoint содержит полную структуру командного декодера. В ходе text-only претрейна были обучены его языковые компоненты, а параметры cross-attention остались неизменёнными.

Список литературы

[1] P. Ramachandran, P. Liu, Q. Le. *Unsupervised Pretraining for Sequence to Sequence Learning*. Proceedings of EMNLP, 2017.

[2] Z. Fan, S. Zhou, B. Xu. *Unsupervised Pre-training for Sequence to Sequence Speech Recognition*. arXiv:1910.12418, 2019.